⚡Worksheet 1 – Enterprise Deployment Clinic

---

1) 🏢 Bối cảnh tổ chức / khách hàng

- Tổ chức: XanhSM (nền tảng gọi xe điện tại Việt Nam)
- Ngành: Vận tải công nghệ
- Quy mô:
  - Hàng chục nghìn tài xế
  - ~100k–500k MAU (ước lượng)
- User chính:
  - External users (khách hàng đặt xe)
  - Persona:
    - Người lớn tuổi (khó thao tác app)
    - Người bận tay (cần thao tác nhanh)

---

2) 🗂️ Dữ liệu hệ thống xử lý

- Data #1: Voice input (audio người dùng nói, 3–10s)
- Data #2: Text sau STT (nội dung yêu cầu đặt xe)
- Data #3: Location data (GPS, địa điểm từ map API)
- Data #4: User history & behavior (địa điểm thường dùng, correction logs)

---

3) 🔒 Đánh giá độ nhạy cảm dữ liệu

Data	Mức độ nhạy cảm	Lý do
Voice input	Cao	Có thể chứa thông tin cá nhân, giọng nói

Data	Mức độ nhạy cảm	Lý do
Location data	Cao	Tiết lộ vị trí người dùng (rất nhạy cảm)
Text sau STT	Trung bình	Nội dung yêu cầu, ít nhạy hơn voice
User history	Cao	Hành vi + thói quen di chuyển

---

4) 🧱 3 ràng buộc enterprise lớn nhất

1. **Latency (Realtime)**
   - Phải phản hồi < 2.5s để đảm bảo trải nghiệm người dùng.
2. **Data privacy & security**
   - Voice + location là dữ liệu nhạy cảm cần đảm bảo không lưu trữ trái phép, bảo mật khi truyền và xử lý.
3. **Cost:**
   - Mỗi request phải gọi nhiều dịch vụ: STT, LLM, Map API.
   - Chi phí tăng tuyến tính theo số lượng user và request.
   - Cần kiểm soát: cost/request

---

5) 🧩 Kiến trúc hệ thống (System Flow)

- **System flow:**

User (Mobile App) → Gửi audio (voice input) → Backend (API Gateway / Orchestrator)

→ STT Service (Speech-to-Text) → LLM Service (Intent + Entity Extraction)

→ Map API (Resolve location) → Ranking + Confidence check

→ UI Confirm (User xác nhận) → Booking System (đặt xe) → Response trả về user

---

6) 🚀 Quyết định deployment

> Lựa chọn: **Cloud**

---

7) ✅ Lý do chọn deployment

- Lý do #1: **Scale lớn + traffic biến động**
  → Cloud dễ autoscale theo giờ cao điểm
- Lý do #2: **Sử dụng AI services (STT, LLM)**
  → Các dịch vụ này thường có sẵn trên cloud (OpenAI, Google, AWS)
- Lý do #3: **Latency + global infra**
  → Cloud có CDN, region gần user → giảm độ trễ

🔄 Data flow chi tiết

- Voice input được gửi từ mobile app → backend
- Audio được xử lý bởi STT service (không lưu lâu dài)
- Text được gửi đến LLM để xử lý intent
- Location data được truy vấn từ map API
- Chỉ lưu:
  - log request (metadata)
  - correction logs để cải thiện system
- Retention:
  - audio: không lưu hoặc lưu tạm (<24h)
  - log: 7–30 ngày
- Truy cập:
  - chỉ backend service và hệ thống nội bộ

⚠️ Rủi ro nếu chọn sai deployment

- Risk #1: **Leak dữ liệu nhạy cảm**
  → nếu xử lý voice/location trên hệ thống không bảo mật
- Risk #2: **Latency cao → UX kém**
  → nếu deploy xa user hoặc không có autoscale

- Risk #3: **Cost tăng mạnh khi scale**
  → nếu không tối ưu AI service hoặc chọn sai hạ tầng