⚡Worksheet 2 – Cost Analysis

1) Giả định hệ thống (Assumptions)

- Users/day: 10,000 user sử dụng tính năng Voice (Tập khách hàng lớn tuổi/quen dùng voice).
- Requests/user/day: 2 requests (1 lượt đi, 1 lượt về).
- Total requests/day: 20,000 requests.
- Peak traffic (optional): 50 req/s (Khung giờ sáng 7h-8h hoặc chiều 17h-18h).
- Avg concurrency (optional): ~5-10 luồng Voice đồng thời.
- Cache hit rate (optional): 15% (Các chuyến đi quen thuộc như "đến công ty", "về nhà").

2) Breakdown 1 request (CỰC QUAN TRỌNG)

Step (pipeline)	Service / SKU	Input size (tokens/giây/MB)	Đơn giá	Cost/req (USD)	Ghi chú (cache/retry/limit)
1) Client → STT	Wit.ai (Meta)	Tối đa 10s audio	$0.00 (Meta cung cấp STT free)	$0.00	User thường nói câu ngắn gọn ("Về nhà", "Đến Vincom")
2) LLM (Extraction)	GPT-4o-mini	~300 in / 100 out tokens	$0.15 (In) / $0.60 (Out) / 1M	~$0.0001	Trích xuất thành JSON (origin, destination, vehicle_type).
3) XanhSM Map API	Internal Location Mapping	1 call	$0.00	$0.00	Match text với toạ độ GPS thực tế. Có cơ chế local cache.
4) UI Render	Mobile App	0	$0.00	$0.00	Trả về thẻ Card UI để user chạm xác nhận. (KHÔNG CẦN TTS)

- Tổng cost/req (USD): ~ $0.0001 / request (Rất rẻ).

3) Cost theo ngày

Thành phần	Công thức nhanh	Cost/ngày (USD)
STT	($0.00/req) × (20,000 req/ngày)	$0.00

Thành phần	Công thức nhanh	Cost/ngày (USD)
LLM	(~$0.0001/req) × (20,000 req/ngày)	$2.00
API/Tool khác	XanhSM Internal Location API	$0.00
Compute (app/worker)	AWS EC2 / ECS container	~$2.00
Storage (DB/vector/object)	Lưu tạm Local (Không lưu Audio vì Privacy)	$0.00
Logging/Tracing/Monitoring	Log metadata (1 GB ingest) × ($0.5/GB)	$0.50
Tổng	—	~$4.50

4) Cost theo tháng (ước lượng)

- Total/month (USD) = ~$135 (= Total/day × 30)
- Fixed/month (USD) = $60 (Compute + Base Storage)
- Variable/month (USD) = $75 (STT + LLM API)
- Cost/user/month (USD) = $135 ÷ 10,000 users = **~$0.014** (= Total/month ÷ 10,000 users/tháng) (Chi phí quá nhỏ so với lợi ích tăng Conversion Rate và giảm Churn Rate của tập KH người lớn tuổi).

5) Cost driver lớn nhất

- **Driver #1: Compute Middleware** (Với mức traffic 20,000 req/ngày, server AWS để hứng request và xử lý logic là chi phí nặng nhất do STT đang được Free).
- **Driver #2: LLM (Extraction)** (Chiếm toàn bộ chi phí API hiện tại do GPT-4o-mini tính phí theo token).

6) Hidden cost (thường bị bỏ qua)

- **VAD Timeout (CỰC KỲ QUAN TRỌNG):** Wit.ai có cơ chế ngắt câu quá nhạy. Tập khách lớn tuổi thường nói ngập ngừng → Wit.ai tự động ngắt sớm → Trích xuất thiếu dữ liệu → Khách bực mình phải nói lại (UX thảm hoạ).
- **Correction Log Pipeline:** Chi phí tính toán để hệ thống học thói quen người dùng (VD: map từ "chỗ cũ" thành toạ độ thực tế).
- **APM/Tracing:** Chi phí giám sát Latency (Langfuse/DataDog) để đảm bảo cam kết <2.5s end-to-end.

7) Nhận xét (1–2 dòng)

- Cost MVP quá lý tưởng nhờ dùng Wit.ai ($0 STT). Tuy nhiên khi lên Production, hệ thống **BẮT BUỘC phải chuyển sang STT trả phí** (VD: FPT.AI / Whisper / Google Cloud) để tùy chỉnh được VAD (xử lý việc nói ngập ngừng) và đảm bảo cam kết SLA.

📈 Cost khi scale (x10 traffic = 200,000 req/ngày)

- Cost/day (x10): ~$35 - $45 / ngày.
- Thành phần tăng mạnh nhất: Token LLM và chi phí scale Server (Compute Middleware) để gánh lượng truy cập cực lớn. (STT vẫn $0 nếu Wit.ai không khoá API).
- Bottleneck: Chạm giới hạn Rate Limit ngầm của bản Free Wit.ai, dẫn đến toàn bộ luồng Voice bị treo vào giờ cao điểm.
- Risk: Wit.ai là hàng Free không có SLA. Khi scale x10, rủi ro sập hệ thống không có người hỗ trợ là cực kỳ lớn. Do đó khi đạt mức Growth này, nhóm **buộc phải đập bỏ Wit.ai** để chi tiền mua STT Enterprise (FPT/Zalo AI) hoặc tự host Whisper, lúc này Cost STT sẽ lập tức quay lại làm Cost Driver số 1.

✅ Checklist nhanh (Enterprise Readiness)

- Budget cap có chưa? Yes (Disable tính năng Voice nếu lố ngân sách, fallback về UI cũ).
- Cơ chế rate limit / quota? Yes
- Cơ chế cache (prompt/response/embedding)? Yes (Lưu bộ mapping địa chỉ local: "Nhà", "Công ty").