# ⚡Worksheet 3 – Cost Optimization

## 1) Cost hiện tại

- Cost/request (USD): **~$0.0001/req** (chủ yếu từ LLM Extraction GPT-4o-mini, STT Wit.ai đang free)
- Cost/day (USD): **~$4.50/ngày**
- Total/month (USD): **~$135/tháng** (Fixed $60 + Variable $75)
- Cost driver chính:
  - **#1 Compute Middleware** (~$60/tháng) — AWS EC2/ECS xử lý pipeline
  - **#2 LLM Extraction** (~$60/tháng) — GPT-4o-mini tính phí theo token
- **Cảnh báo:** Khi scale x10 hoặc chuyển Production, bắt buộc thay Wit.ai bằng STT trả phí → STT sẽ trở thành cost driver #1.

## 2) Các chiến lược tối ưu

### Strategy 1: Model Routing — Cheap model cho simple, Expensive cho complex

- **Mục tiêu:** Tiết kiệm **40–60% token cost**, giữ Entity Precision ≥95%.
- **Giảm cost ở đâu:** Step 2 (LLM Extraction) — phần lớn request đi qua model rẻ, chỉ escalate model lớn khi thực sự cần.
- **Cách làm:**
  - **Tier 1 — Rule-based / Regex (free):** Match các pattern cố định ("về nhà", "đến công ty") + địa chỉ có số nhà rõ ràng từ user dictionary.
  - **Tier 2 — GPT-4o-mini / Claude Haiku (~$0.25/1M in):** Câu đơn giản, entity rõ ràng (~70% traffic).
  - **Tier 3 — GPT-4o / Claude Sonnet (~$3/1M in):** Chỉ dùng khi Tier 2 confidence <70%, câu mơ hồ có nhiều landmark trùng tên (giải quyết failure mode "Vincom nào?" trong spec), hoặc giọng địa phương khó.
- **Trade-off:**
  - **Cost:** ↓ 40–60% LLM cost nhờ Tier 1 free + Tier 2 rẻ chiếm phần lớn.
  - **Quality:** ↑ nhẹ cho câu khó (nhờ Tier 3 model lớn), rule-based Tier 1 có thể miss edge case → cần fallback.

- **Latency:** ↓ cho Tier 1 (~100ms), ↑ nhẹ cho Tier 3 (~2s, vẫn trong SLA 2.5s).

- **Guardrail:**
  - End-to-end latency p95 ≤2.5s (SLA cứng trong spec).
  - Rule-based confidence <95% → bắt buộc escalate lên Tier 2.
  - Clarification Rate <20%.
- **Khi nào áp dụng:** Toàn bộ traffic; Tier 1 ưu tiên cho user cũ có history, Tier 3 dành cho user mới hoặc giọng địa phương.

---

## Strategy 2: Semantic Caching — Cache LLM responses cho similar queries

- **Mục tiêu:** Tiết kiệm **20–40% LLM cost** khi queries lặp lại (rất phù hợp với behavior đặt xe).
- **Giảm cost ở đâu:** Step 2 (LLM Extraction) — bỏ qua hoàn toàn lời gọi LLM khi câu nói đã từng được xử lý.
- **Cách làm:**
  - Dùng embedding similarity (sentence-transformers, ~$0 nếu self-host nhỏ) để match câu nói mới với câu đã cache — tolerate được sự khác biệt nhỏ ("đến Vincom Bà Triệu" ≈ "cho tôi tới Vincom Bà Triệu").
  - Cache key: embedding vector + user_id + GPS cluster (bán kính 500m); TTL 30 ngày cho user-specific, 7 ngày cho global popular queries.
  - Tận dụng Data Flywheel đã thiết kế trong User Stories: mỗi correction làm giàu personal dictionary → cache hit rate tăng theo thời gian.
- **Trade-off:**
  - **Cost:** ↓ 20–40% LLM cost (phù hợp với cache hit rate 15% baseline, có thể tăng 30%+ khi user dùng lâu).
  - **Quality:** Rủi ro cache stale nếu user đổi địa chỉ "nhà" → cần invalidation chặt.
  - **Latency:** ↓ đáng kể (~1.3s cho cache hit, còn ~200ms).
- **Guardrail:**
  - Similarity threshold ≥0.92 mới coi là cache hit.
  - Vẫn hiển thị màn hình xác nhận (augmentation principle trong spec) — user luôn thấy và duyệt kết quả.
  - Invalidate cache ngay khi user sửa correction gần đây.
- **Khi nào áp dụng:** User có history ≥3 booking, câu nói phổ biến ("về nhà", "đến công ty"), trong cùng GPS cluster.

---

### Strategy 3: Prompt Compression — Tóm tắt context trước khi gửi LLM

- **Mục tiêu:** Tiết kiệm **15–30% input tokens** mà vẫn giữ thông tin cần thiết cho extraction.
- **Giảm cost ở đâu:** Step 2 (LLM Extraction) — giảm input tokens từ ~300 xuống ~180 tokens/request.
- **Cách làm:**
  - Compress system prompt: chỉ giữ 2 few-shot examples đại diện (origin/destination) thay vì 5–6; chuyển các validation rule phức tạp sang hậu xử lý bằng code.
  - Chỉ truyền context thực sự cần: GPS hiện tại + top 3 địa điểm gần nhất trong history (thay vì toàn bộ 20+ địa điểm).
  - Normalize input audio transcript: bỏ filler words ("ờ", "ừm", "cái"), giữ nguyên tên riêng và số nhà.
- **Trade-off:**
  - **Cost:** ↓ input token ~40%, tương ứng ~20% tổng LLM cost.
  - **Quality:** Có thể giảm nhẹ nếu bỏ quá nhiều context → cần A/B test ngưỡng an toàn.
  - **Latency:** ↓ ~100–200ms do input nhỏ hơn.
- **Guardrail:**
  - Precision không giảm quá 1% so với baseline.
  - Giữ nguyên personal dictionary ("chỗ cũ", "nhà cô Lan") — **không được compress** phần này.
- **Khi nào áp dụng:** Toàn bộ traffic, đặc biệt hiệu quả khi scale x10 vì input token chiếm phần lớn cost.

---

## 3) Ước lượng tiết kiệm

- (Gợi ý: ghi rõ baseline; dùng cùng đơn vị như Worksheet 2)

| Strategy | Baseline liên quan | % tiết kiệm | Cost mới | Tác động latency | Tác động quality |
|---|---|---|---|---|---|
| 1) Model Routing | LLM $2/ngày | 40–60% | ~$0.80–1.20/ngày | – 500ms p50 | +1–2% precision |
| 2) Semantic Cache | LLM $2/ngày | 20–40% | ~$1.20–1.60/ngày | – 1.3s cho cache hit | Trung tính (có guardrail) |
| 3) Prompt Compression | LLM $2/ngà | 15–30% | ~$1.40–1.70/ngày | – 150ms | −0.5 đến −1% precision |
| Combined | $4.50/ngày | ~55–65% | ~$1.80/ngày | – 600ms p50 | +1% precision |

| Strategy | Baseline liên quan | % tiết kiệm | Cost mới | Tác động latency | Tác động quality |
|---|---|---|---|---|---|
| 1+2+3 (MVP) | | | | | |

## 4) So sánh trước vs sau

| Chỉ số | Trước | Sau | Ghi chú |
|---|---|---|---|
| Cost/request (USD) | $0.0001 | ~$0.00004 | Tier 1 free + cache hit chiếm ~35% |
| Cost/day (USD) | $4.50 | ~$1.80 | Tiết kiệm ~$81/tháng, ~$972/năm |
| Latency p50 / p95 (ms) | 1500 / 2400 | 900 / 2300 | Vẫn trong SLA 2.5s |
| Quality (metric chính) | 95% | 95–96% | Tier 3 bù cho câu khó |
| Tỷ lệ fallback / error | ~8% | 10–12% | Tăng nhẹ do rule-based strict, vẫn <20% |

## 5) Rủi ro khi tối ưu quá mức

- **Rủi ro #1 — Cache stale gây booking sai:** User chuyển nhà nhưng cache còn giữ toạ độ cũ → AI hiển thị sai → user bấm xác nhận nhanh → xe đến sai điểm. **Hậu quả:** Rơi vào failure mode nguy hiểm nhất (silent wrong) trong spec, mất uy tín với nhóm user lớn tuổi. **Mitigation:** TTL ngắn cho user-specific cache (7 ngày), invalidate ngay khi có correction, similarity threshold cao (≥0.92), luôn bắt buộc màn hình xác nhận.
- **Rủi ro #2 — Rule-based / compressed prompt miss giọng địa phương:** Tier 1 và prompt compression không xử lý được câu nói ngập ngừng, giọng vùng miền của user lớn tuổi (target chính) → false negative → tăng Clarification Rate → user bực mình → churn. **Hậu quả:** Mâu thuẫn trực tiếp với value proposition. **Mitigation:** Confidence threshold cao cho Tier 1 (≥95%), mặc định escalate lên Tier 2/3 khi nghi ngờ, monitor Clarification Rate daily với alert ở 25%.

## 6) Quyết định tối ưu cuối cùng (production decision)

- **Chọn cho MVP: Strategy 1 (Model Routing) làm primary + Strategy 2 (Semantic Cache) làm secondary + Strategy 3 (Prompt Compression) bật sau 2 tuần A/B**.
- **Lý do:**
  - Strategy 1 cho ROI cao nhất (40–60%) và **tăng** chất lượng cho câu khó nhờ Tier 3 — giải quyết đúng failure mode "địa điểm mơ hồ" trong spec.
  - Strategy 2 cộng hưởng với Data Flywheel đã thiết kế — mỗi correction làm giàu cache → tiết kiệm tăng theo thời gian.
  - Strategy 3 risk nhẹ lên precision → bật sau khi có data baseline.

- **Kế hoạch rollout:**
  - **Phạm vi:** 10% traffic tại Hà Nội, ưu tiên user có ≥5 booking history.
  - **A/B:** 50/50 trong 2 tuần — control dùng GPT-4o-mini đơn tầng, treatment dùng routing 3-tier + cache.
  - **Ngày bắt đầu:** Sprint tiếp theo sau khi MVP qua UAT.
- **KPI theo dõi sau rollout:**
  - **Cost:** Cost/successful_booking giảm ≥40%, tổng cost/day ≤$2.
  - **Latency:** p50 ≤1s, p95 ≤2.5s.
  - **Quality:** Entity Precision ≥95%, Clarification Rate <20%, Successful Confirmation Rate ≥85%.

---

# (Optional – nâng cao để ăn điểm)

## 🧠 Intelligent routing logic

- **Tín hiệu routing:**
  - User history depth (mới vs cũ) — user cũ có dictionary cá nhân → ưu tiên Tier 1.
  - Pattern matching với "common queries" ("về nhà", "đến công ty") → Tier 1.
  - STT confidence từ Wit.ai/Whisper — <0.8 → bỏ qua Tier 1.
  - Geographic risk: nhiều địa điểm trùng tên trong bán kính 5km (nhiều Vincom) → escalate Tier 3.
- **Pseudocode:**
  - `If cache_hit (similarity ≥0.92) AND not recently_corrected → return cached result ($0)`
  - `Else if pattern ∈ user_dictionary AND stt_confidence ≥0.9 → Tier 1 rule-based ($0)`
  - `Else if entity_count ≤2 AND no_ambiguous_landmark → Tier 2 GPT-4o-mini ($0.25/1M)`
  - `Else if stt_confidence <0.7 OR multiple_matches ≥3 → Tier 3 GPT-4o ($3/1M) + forced clarification`
  - `Fallback → UI nhập tay + gợi ý địa điểm quen`

---

## 📊 Impact đến system (Enterprise Readiness)

- **Latency:** p50 ↓ 600ms nhờ Tier 1 free-path + cache hit; p95 ổn định nhờ circuit breaker khi Tier 3 chậm.
- **Accuracy/Quality:** Precision giữ hoặc ↑ (+1–2%) nhờ Tier 3 cho câu khó — đặc biệt có lợi cho user lớn tuổi/giọng địa phương.

- **User experience:** User mới được routing lên Tier 2/3 mặc định (an toàn), user cũ hưởng trải nghiệm nhanh hơn — đúng triết lý "cold start = an toàn, lâu dài = cá nhân hóa" trong spec.
- **Observability:**
  - Cost per tenant tracking qua Langfuse (segment: elderly vs busy-hands).
  - Budget cap: alert ở 80%, auto-disable Tier 3 ở 100%, fallback toàn bộ về Tier 2.
  - Dashboard realtime: cost/successful_booking, tier distribution (%), cache hit rate, Clarification Rate theo giờ.
  - Kill switch: Disable Voice feature nếu chi phí API >2,000 VNĐ/booking (kill criteria trong spec).