⚡Worksheet 4 – Scaling & Reliabilit

---

0) Thông tin hệ thống

- **Tên hệ thống / scenario:** XanhSM Voice Booking – đặt xe điện bằng giọng nói
- **Luồng chính:** User nói → STT → LLM (intent/entity) → Map API → Confirm UI → Booking System
- **Traffic & kênh vào:** Mobile App (iOS/Android), voice input 3–10s, ~100k–500k MAU; peak giờ đi làm (7–9h, 17–19h)
- **Dependency chính:** STT Service (Google/AWS), LLM (OpenAI/Gemini), Map API (Google Maps), Booking DB, Payment Gateway
- **Giả định quan trọng:** Latency E2E phải < 2.5s; audio không lưu quá 24h; hệ thống deploy trên Cloud (single region VN)

---

1) Các tình huống hệ thống cần xử lý

Case 1: Traffic tăng đột biến (peak hour)

- **Trigger / dấu hiệu:** Giờ cao điểm 7–9h & 17–19h; số request tăng 5–10x so với baseline; queue depth tăng vọt
- **Vấn đề (failure mode):** Backend orchestrator bị quá tải, request xếp hàng > 5s, timeout lan rộng; STT/LLM provider bị chạm rate limit
- **Ảnh hưởng (user + business):** User chờ quá lâu → bỏ đặt xe → mất doanh thu; tài xế không nhận được booking → idle
- **Tài nguyên bị căng:** API Gateway connections, LLM token/min rate limit, Map API quota, DB connection pool
- **Guardrail cần có:** Rate limit per user (e.g. 5 req/min), request queue với priority, load shedding bỏ request quá cũ (> 3s trong queue), autoscale

worker

Case 2: AI service bị lỗi (STT / LLM fail)

- **Trigger / dấu hiệu:** Error rate STT/LLM > 5% trong 1 phút; response time > 3s liên tục; HTTP 5xx từ provider
- **Vấn đề (failure mode):** STT trả về empty/garbage text; LLM timeout hoặc hallucinate địa chỉ sai; toàn bộ luồng voice bị gãy
- **Ảnh hưởng:** User không đặt được xe bằng giọng nói; nếu không có fallback → mất 100% voice booking session
- **Lỗi thường gặp:** STT timeout, LLM 429 (rate limit), LLM trả địa chỉ không tồn tại (hallucination), confidence score thấp
- **Guardrail cần có:** Circuit breaker cho STT & LLM riêng biệt; fallback sang nhập tay; manual confirm khi confidence < 0.7

Case 3: Response chậm (latency cao)

- **Trigger / dấu hiệu:** P95 E2E > 2.5s; user thấy spinner > 3s; tăng abandon rate trên màn hình confirm
- **Vấn đề (failure mode):** Chuỗi STT → LLM → Map API chạy tuần tự; một bước chậm kéo cả pipeline trễ
- **Ảnh hưởng:** Trải nghiệm kém đặc biệt với người lớn tuổi; tăng tỷ lệ retry → càng tăng tải hệ thống
- **Nguồn gây trễ:** STT cold start (~500ms), LLM inference (~800–1200ms), Map API geocoding (~300ms), DB lookup lịch sử địa điểm (~100ms)
- **Guardrail cần có:** Timeout cứng mỗi bước; chạy Map API song song với LLM khi có thể; cache địa điểm thường dùng; streaming response hiển thị partial result

---

2) Giải pháp ngắn hạn (Immediate fixes)

- **Retry:** Chỉ retry với lỗi transient (timeout, 5xx); max 2 attempts; exponential backoff 200ms → 400ms; không retry 4xx

- **Timeout:** STT ≤ 1.5s; LLM ≤ 1.5s; Map API ≤ 500ms; toàn pipeline hard timeout 2.5s
- **Fallback tạm thời:** Nếu STT fail → hiển thị ô nhập địa chỉ tay; nếu LLM fail → rule-based keyword matching (tên quận/phường); nếu Map fail → dùng cache địa điểm gần nhất của user
- **Giảm tải (load shedding):** Tắt tính năng gợi ý địa điểm nâng cao; giới hạn 3 req/user/phút; drop request đã chờ > 3s trong queue
- **Runbook ngắn:** (1) Check dashboard error rate → (2) Xác định component lỗi (STT/LLM/Map) → (3) Kích hoạt circuit breaker thủ công nếu cần → (4) Bật fallback mode toàn hệ thống → (5) Notify on-call + post incident channel

---

3) Giải pháp dài hạn (System design)

- **Kiến trúc xử lý:** Async pipeline: audio upload → message queue (SQS/Pub-Sub) → worker pool (STT worker, LLM worker chạy độc lập) → kết quả push về client qua WebSocket
- **Scaling strategy:** HPA cho STT worker & LLM orchestrator (scale theo queue depth); warm pool 2–3 instance thường trực để tránh cold start; GPU pool cho STT nếu self-host; concurrency limit 50 req/worker
- **Isolation:** Tách STT service và LLM service thành microservice riêng với resource quota độc lập (bulkhead); tách luồng peak user khỏi batch processing nội bộ; mỗi service có circuit breaker riêng
- **Data & cache:** Cache địa điểm thường dùng của user (Redis, TTL 7 ngày); cache geocoding kết quả Map API (TTL 24h); cache stampede guard bằng mutex lock khi cache miss đồng thời; cache key = `user_id:location_alias`
- **Resilience pattern:** Circuit breaker (half-open sau 30s); hedged requests cho Map API (gửi 2 request, lấy kết quả nhanh hơn); idempotency key cho booking request để tránh đặt xe 2 lần khi retry

---

4) Fallback strategy

Component	Fallback (làm gì)	Trigger / điều kiện kích hoạt	User experience (hiển thị gì)
STT	Chuyển sang nhập địa chỉ tay	Timeout > 1.5s hoặc error rate > 10% trong 60s	"Không nhận được giọng nói, vui lòng nhập địa chỉ" + ô text hiện ra
LLM	Rule-based keyword matching (tên quận, landmark phổ biến)	HTTP 5xx, timeout > 1.5s, hoặc confidence < 0.5	Hiển thị gợi ý địa điểm từ rule engine; nếu vẫn fail → yêu cầu nhập tay
Map API (geocoding)	Dùng cache địa điểm đã dùng gần nhất của user	Timeout > 500ms hoặc 5xx từ provider	Hiển thị địa điểm từ lịch sử, user xác nhận lại trước khi đặt
Core Backend	Trả về lỗi graceful, giữ session; tự động retry sau 5s	Health check fail, DB connection pool cạn	"Hệ thống đang bận, đang thử lại..." + spinner; sau 2 lần fail → "Vui lòng thử lại sau"

5) Monitoring & Metrics

Nhóm metric	Metric cụ thể	Ngưỡng cảnh báo	Dashboard / nguồn
Latency	P50 / P95 / P99 end-to-end; P95 theo từng component	P95 > 2s → warning; P95 > 2.5s → alert	Grafana / CloudWatch
Reliability	Error rate (5xx) toàn pipeline; timeout rate per component; retry rate; circuit breaker open count	Error rate > 2% → warning; > 5% → page on-call	Grafana + PagerDuty
Quality (AI)	STT: WER (word error rate) trên sample; LLM: intent success rate, entity accuracy; low-confidence rate (< 0.7)	Low-confidence rate > 20% → review prompt; WER > 15% → check STT model	Internal eval dashboard
Saturation	CPU/GPU util, queue depth, DB connections, rate-limit hits	Queue depth > 500 → scale out; CPU > 80% → alert	CloudWatch / Datadog

Nhóm metric	Metric cụ thể	Ngưỡng cảnh báo	Dashboard / nguồn
Cost	Cost/request, token/sec, GPU-hour, cache hit rate	Cost/request > $0.02 → review; cache hit < 60% → investigate	Cost dashboard (AWS/GCP)

- **Alert routing / on-call:** P1 (circuit open, error rate > 5%) → page on-call engineer ngay; P2 (latency warning, queue depth cao) → Slack alert #incident; P3 (cost spike, low-confidence tăng) → daily digest email

---

6) SLA / SLO (optional nhưng rất ăn điểm)aqqaaa

- **Latency target (E2E):** P95 ≤ 2.5s; P99 ≤ 4s (tính từ khi user nói xong đến khi màn hình confirm hiện ra)
- **Availability:** 99.5% / tháng (~3.6h downtime cho phép) — thực tế target nội bộ 99.9%
- **Success rate:** ≥ 95% voice booking session hoàn thành không cần fallback về nhập tay
- **Accuracy / quality proxy:** LLM intent accuracy ≥ 90% trên test set; STT WER ≤ 10% với giọng Việt; user accept rate (không sửa địa chỉ) ≥ 80%
- **Error budget & chính sách:** Error budget = 0.5% downtime/tháng (~3.6h). Nếu vượt 50% budget → dừng mọi rollout feature mới; vượt 100% → post-mortem bắt buộc + freeze deployment 1 tuần

---

7) Nhận xét (kết luận nhanh)

Hệ thống **có thể đạt reliable** nếu triển khai đầy đủ circuit breaker + fallback rõ ràng cho từng AI component. **Rủi ro lớn nhất** là chuỗi STT → LLM → Map API chạy tuần tự tạo ra latency cộng dồn — một bước chậm là fail toàn pipeline; cần ưu tiên song song hoá và cache địa điểm ngay từ đầu.

⚠️ Điểm nghẽn (bottleneck)

- **Bottleneck #1: LLM inference latency** | **Đo:** P95 thời gian LLM response, token throughput | **Giảm:** Prompt ngắn gọn, dùng model nhỏ hơn (fine-tuned) cho task đặt xe, enable streaming
- **Bottleneck #2: Map API geocoding tuần tự** | **Đo:** % request phải gọi Map API live vs cache hit rate | **Giảm:** Pre-cache top 1000 địa điểm phổ biến tại VN, chạy Map API song song với LLM call

---